



Escuela de Ingeniería en computación

Programa Maestría en Computación

MC6104 - Diseño de Experimentos

## **Apuntes clase 02/03/2023**

Aarón Sibaja Villalobos  
2018319668

San José, Costa Rica

marzo, 2023

# Índice de contenidos

<b>1. Inferencia Estadística</b>	<b>1</b>
<b>2. Pruebas de Hipótesis</b>	<b>1</b>
2.1. Hipótesis Nula . . . . .	1
2.2. Hipótesis Alternativa . . . . .	1
2.3. P-value . . . . .	1
2.4. Visualización del P-value . . . . .	1
<b>3. Errores de Inferencia</b>	<b>2</b>
<b>4. T-test</b>	<b>2</b>
4.1. Distribución T . . . . .	3
4.2. Ejemplo R T-test . . . . .	4
4.3. Conclusiones . . . . .	8
<b>5. Distribución Normal</b>	<b>8</b>
5.1. Pruebas de normalidad . . . . .	9
<b>6. Gráficos Q-Q</b>	<b>9</b>
<b>7. Anova monofactorial</b>	<b>9</b>
7.1. Supuestos . . . . .	10
7.2. Ejemplo R Anova . . . . .	10
7.3. Gráficos de Intervalos de Confianza . . . . .	12
7.4. Modelo Lineal . . . . .	14
7.5. Ejecución del Anova . . . . .	14
<b>Referencias</b>	<b>15</b>

# 1. Inferencia Estadística

Utiliza pruebas estadísticas para genera una conclusión. Se utiliza ampliamente en los campos de la medicina.

Es importante resaltar que para asegurar que las muestras son representativas a la población, esta debe de ser seleccionada de manera completamente aleatoria.

**Ejemplo:** Inferir el tiempo de espera de una persona realizando encuestas a 10 unidades de emergencia.

## 2. Pruebas de Hipótesis

### 2.1. Hipótesis Nula

Se supone, en principio, lo contrario de lo que se desea probar, hasta que los datos y pruebas obtenidas demuestran que el punto de partida era falso, por lo tanto se rechaza.

**Ejemplo:** Dos grupos no son iguales, no hay correlación entre dos variables. Etc

### 2.2. Hipótesis Alternativa

Contraria a la hipótesis nula, los grupos son iguales y hay una correlación entre dos variables.

### 2.3. P-value

Asumiendo que la hipótesis nula es verdadera, es la probabilidad de obtener un resultado igual o más extremo a lo obtenido por los datos.

### 2.4. Visualización del P-value

**Problema:** se va tirar una moneda 100 veces

**Hipótesis Nula:**

La moneda es justa, existe la misma probabilidad de caer en escudo o corona, o cara o cruz

Hipótesis Alternativa:

La moneda no es justa.

El resultado que tenemos es que la moneda cayó en escudo 95 de las veces.

95 % corresponde a un  $\alpha = 0,05$  entonces,  $p\text{-value} = 0,05$

### 3. Errores de Inferencia

Puede darse el caso de que los resultado que se obtuvieron, aunque improbables, sean el resultado de la casualidad.

Error Tipo I:

El error de tipo I se comete cuando la hipótesis nula es verdadera y, para esta es rechazada. La probabilidad de cometer el error de tipo I es el nivel de significación de  $\alpha$ .

Error Tipo II:

El error de tipo II se comete cuando la hipótesis nula es falsa y, pero esta se acepta.



	Naturaleza de $H_0$	
	Verdadera	Falsa
Decisión sobre $H_0$		
No rechazar Mantener	Acierto Nivel de confianza $1-\alpha$	Error Error tipo 2 $\beta$
Rechazar	Error Error tipo 1 $\alpha$	Acierto Potencia del contraste $1-\beta$

### 4. T-test

También conocida como prueba t de Student, corresponde a una herramienta para evaluar las medias de uno o dos grupos mediante yu cómo estan relacionados mediante pruebas de hipótesis.

Ejemplo: Se crea un algoritmo nuevo que permite mejorar los tiempos de entrenamiento para una red neuronal y se quiere comparar contra la mejor solución conocida hasta el momento:

En este caso, al "Método de Entrenamiento" se le llama factor y los niveles de nuestro factor son "Algoritmo A(viejo)" y "Algoritmo B(Nuevo)".

Cuadro 1: Componentes del T-test

	<b>Factor</b>
	Método de Entrenamiento
<b>Niveles</b>	Algoritmo 1
	Algoritmo 2

La tabla 1 puede contener más factores y niveles, si embargo se requiere otro tipo de prueba.

Para aplicar el T-test se deben de cumplir algunos requerimientos:

- Los datos de ambas poblaciones deben de estar normalmente distribuidas.
- Ambas poblaciones tienen la misma varianza.
- En R, se puede utilizar la Welch's T-test cuando no tengamos la misma varianza

Student T-test

$$t = \frac{\bar{X}_1 - \bar{X}_2}{s_p \sqrt{\frac{2}{n}}} \quad (1)$$

es matemáticamente igual a un Anova mono factorial con dos niveles


$$s_p \sqrt{\frac{s_{x1}^2 - s_{x2}^2}{2}} \quad (2)$$

- La Diferencia de promedios se calcula en el numerador. Entre más grande la diferencia más grande el numerador.
- El denominador es el error estándar de la diferencia de promedios. Se vuelve más pequeño si el tamaño de la muestra aumenta. También se le conoce como desviación estándar combinada.
- El valor de  $t$  se hace grande si la diferencia entre promedios es grande, si las varianzas disminuye, o si el tamaño de la muestra aumenta.
- Se calcula la probabilidad de observar  $t$  bajo la hipótesis nula utilizando la distribución  $t$

#### 4.1. Distribución T

Corresponde a la distribución de la ubicación del promedio de la muestra relativa al promedio verdadero dividido entre la desviación estándar de la muestra multiplicado por  $\sqrt{n}$

Se puede utilizar para construir un intervalo de confianza sobre el promedio verdadero y verificar la diferencia entre el promedio de dos poblaciones.



- Cuando hacemos un t-test verificamos si la prueba estadística es un valor más extremo que el esperado de la distribución  $t$
- Rechazamos la hipótesis nula si estamos fuera del valor
- Los grados de libertad están asociados al tamaño de la muestra.
- Para tamaños grandes podemos utilizar la distribución  $Z$

#### Distribución t de Student::

Es una distribución de probabilidad que surge del problema de estimar la media de una población normalmente distribuida cuando el tamaño de la muestra es pequeña y la desviación estándar poblacional es desconocida. La desviación de la población se estima a partir de la muestra.

## 4.2. Ejemplo R T-test

Es necesario instalar las librerías necesarias

```
1 install.packages("mnormt")
2 if(!require(psych)){install.packages("psych", dependencies = TRUE)}
3 if(!require(FSA)){install.packages("FSA")}
4 if(!require(lattice)){install.packages("lattice")}
5 if(!require(lsr)){install.packages("lsr")}
6 if(!require(lsr)){install.packages("rcompanion")}
```

Se deben de cargar los datos en formato texto y para luego parsear el texto en un objeto DataFrame

```
1
2 Datos = ("
```

```

3           Algoritmo      Ejecucion  Tiempo
4 'Algoritmo A' '1'         12070
5 'Algoritmo A' '2'         14040
6 'Algoritmo A' '3'         13580
7 'Algoritmo A' '4'          9540
8 'Algoritmo A' '5'         14070
9 'Algoritmo A' '6'         11520
10 'Algoritmo A' '7'         13030
11 'Algoritmo A' '8'         13245
12 'Algoritmo A' '9'         14215
13 'Algoritmo A' '10'        15070
14 'Algoritmo A' '11'        12580
15 'Algoritmo A' '12'        11540
16 'Algoritmo A' '13'         9580
17 'Algoritmo A' '14'        11510
18 'Algoritmo A' '15'        16070
19 'Algoritmo A' '16'        13010
20 'Algoritmo A' '17'        10530
21 'Algoritmo A' '18'        13030
22 'Algoritmo A' '19'        17080
23 'Algoritmo A' '20'        13020
24 'Algoritmo B' '1'         11070
25 'Algoritmo B' '2'         12010
26 'Algoritmo B' '3'         12550
27 'Algoritmo B' '4'         10500
28 'Algoritmo B' '5'         12000
29 'Algoritmo B' '6'         12520
30 'Algoritmo B' '7'         13520
31 'Algoritmo B' '8'         13540
32 'Algoritmo B' '9'         13255
33 'Algoritmo B' '10'        15235
34 'Algoritmo B' '11'        12235
35 'Algoritmo B' '12'        11285
36 'Algoritmo B' '13'        10040
37 'Algoritmo B' '14'        11295
38 'Algoritmo B' '15'        14080
39 'Algoritmo B' '16'        12080
40 'Algoritmo B' '17'        11580
41 'Algoritmo B' '18'        14070
42 'Algoritmo B' '19'        15050
43 'Algoritmo B' '20'        12050
44      ")
45
46 Data = read.table(textConnection(Datos), header = T)
47
48 rm(Datos)

```

Seguidamente se orden los datos

```

1 library(psych)
2 headTail(Data)

```

con el siguiente Output:

```

           Algoritmo Ejecucion Tiempo
1  Algoritmo A           1  12070
2  Algoritmo A           2  14040
3  Algoritmo A           3  13580
4  Algoritmo A           4   9540
...      <NA>         ...    ...
37 Algoritmo B          17  11580
38 Algoritmo B          18  14070
39 Algoritmo B          19  15050
40 Algoritmo B          20  12050

```

Se debe de realizar un resumen de los datos que permita analizar la metadata y los tipos de datos. La siguiente función muestra y examina algunas medidas de tendencia central

```

1 # Resumen Datos
2 str(Data)
3 summary(Data)

```

Esto tiene el siguiente output:

```

> str(Data)
'data.frame':  40 obs. of  3 variables:
 $ Algoritmo: chr  "Algoritmo A" "Algoritmo A" "Algoritmo A" "Algoritmo A" ...
 $ Ejecucion: int   1  2  3  4  5  6  7  8  9 10 ...
 $ Tiempo   : int  12070 14040 13580 9540 14070 11520 13030 13245 14215 15070 ...
> summary(Data)
  Algoritmo      Ejecucion      Tiempo
Length:40      Min.   : 1.00   Min.   : 9540
Class :character 1st Qu.: 5.75   1st Qu.:11535
Mode  :character Median :10.50   Median :12565
                        Mean  :10.50   Mean  :12707
                        3rd Qu.:15.25   3rd Qu.:13695
                        Max.   :20.00   Max.   :17080

```

En la imagen ?? hay dos errores. El primero es que no tiene mucho sentido sacar medidas de posición central para una variable discreta como Ejecución. Por otra parte, no está considerando que hay dos clases de algoritmos y lo está tomando como un todo.

Ahora resumiendo los datos por grupo se tiene lo siguiente:

```

1 library(FSA)
2 Summarize(Tiempo ~ Algoritmo, data=Data, digits=4)

```

Esto nos da como resultado un resumen de las medidas de posición central para cada Algoritmo A y B

	Algoritmo	n	mean	sd	min	Q1	median	Q3	max
1	Algoritmo A	20	12916.50	1942.198	9540	11535.00	13025.0	14047.5	17080
2	Algoritmo B	20	12498.25	1422.549	10040	11508.75	12157.5	13525.0	15235


Luego se separa los datos en los grupos A y B, y seguidamente se grafica el histograma para cada uno.

```


1
2 A = Data$Tiempo[Data$Algoritmo == 'Algoritmo A']
3 B = Data$Tiempo[Data$Algoritmo == 'Algoritmo B']
4
5 library(rcompanion)
6
7 plotNormalHistogram(A)
8 plotNormalHistogram(B)

```





(a) Algoritmo A



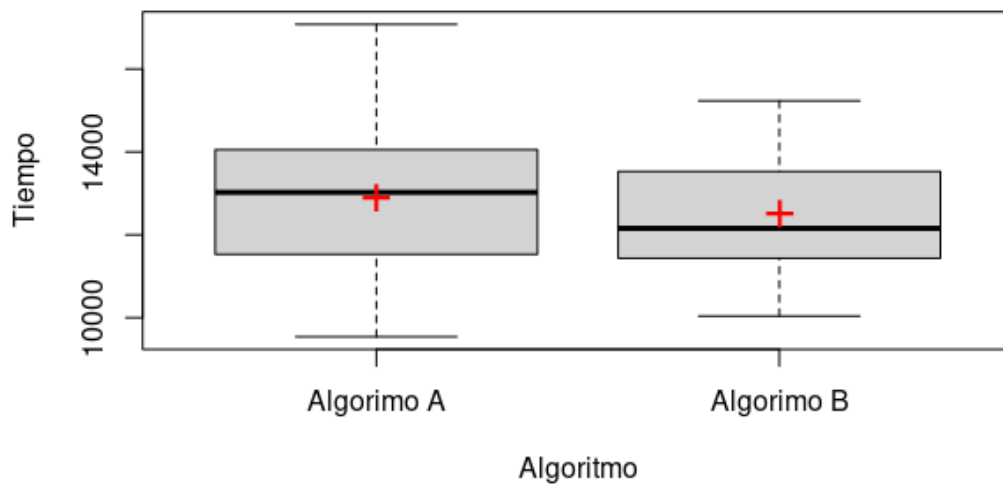
(b) Algoritmo B

Figura 1: Histogramas de los dos tipos de Algoritmos

Cómo no tenemos la información completa, es necesario realizar diagramas de caja para cada grupo (Algoritmo A y B)

```
1 M = tapply(Data$Tiempo, Data$Algoritmo, mean)
2
3 boxplot(Tiempo ~ Algoritmo, data=Data)
4
5 points(M, col="red", pch="+", cex=2)
```

Esto nos da cómo resultado lo siguiente:



En la imagen ??, la cruz roja corresponde a la media, la línea negra corresponde a la mediana o también el segundo cuartil. Además, la primera línea horizontal de abajo hacia arriba corresponde al primer cuartil y la segunda corresponde al tercero. El primer cuartil denotar que el 25% de los datos por debajo de ese valor. Los vigotes se pueden utilizar como el rango o valor máximo y mínimos de los datos.

Ahora aplicando la prueba T en R, se tiene que:

```
1 t.test(Tiempo ~ Algoritmo, data= Data)
```

Esto nos da cómo resultado lo siguiente:

```
Welch Two Sample t-test

data: Tiempo by Algoritmo
t = 0.77695, df = 34.83, p-value = 0.4424
alternative hypothesis: true difference in means between group Algoritmo A and group Algoritmo B is not equal to 0
95 percent confidence interval:
 -674.7892 1511.2892
sample estimates:
mean in group Algoritmo A mean in group Algoritmo B
      12916.50             12498.25
```

De la imagen anterior podemos determinar que no podemos rechazar  $H_0$ , la hipótesis nula la definimos como que ambos grupos no son distintos. Ya que el  $p\text{-value} = 0,4424$ , no rechazamos la hipótesis nula, para rechazarla se ocupa un valor de  $p\text{-value} = 0,044$

### 4.3. Conclusiones

El promedio de tiempo de entrenamiento de nuestro algoritmo (nuevo) no es suficiente ni menor con respecto al otro algoritmo(viejo) comparado

- Nuestro resultado no es estadísticamente significativo o menor al otro.
- Este análisis es fácilmente replicable en un sin fin de experimentos donde se comparen dos sistemas, dos poblaciones, etc.

## 5. Distribución Normal

- Generalmente es requerida para las pruebas paramétricas
- Para la prueba se requiere que los residuos sean normales

Residuos:

Diferencia entre las observaciones y el valor predicho por el modelo.

La t-test es robusta a violaciones de normalidad para distribuciones simétricas (se pueden tolerar pequeñas violaciones). Por otro lado, las violaciones evidentemente grandes invalidan la prueba.

## 5.1. Pruebas de normalidad

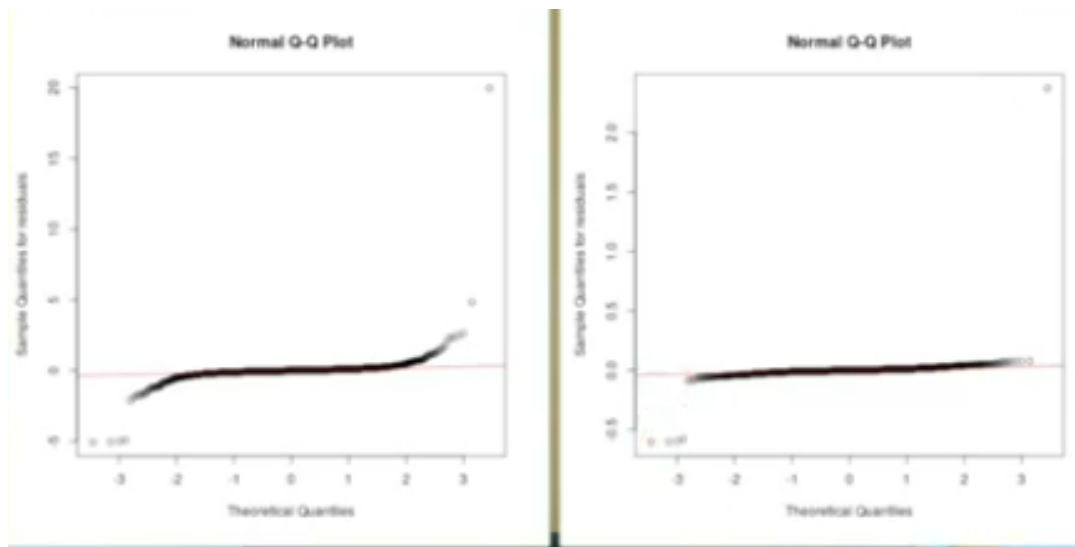
- Shapiro - Wilk
- Anderson - Darling
- Kolmogorov - Smirnov
- D'Agostino - Pearson

Lamentablemente las pruebas anteriores dependen de un tamaño de muestra grande. Por eso, con una muestra más pequeña una evaluación visual es lo suficientemente bueno como para asumir normalidad para el conjunto de datos.

## 6. Gráficos Q-Q

Corresponde a un diagrama de puntos que grafica las funciones de distribución acumuladas. En caso de que provengan de una misma distribución los puntos aparecen alineados en el gráfico. Es utilizada para determinar si la muestra sigue una distribución teórica, esta puede ser una distribución normal por ejemplo.

Este tipo de gráficos permite determinar outliers, es más fácil de evaluar visualmente que un histograma.



## 7. Anova monofactorial

Se utiliza cuando se quieren comparar más de dos grupos. Por ejemplo utilizando la variable dependiente tiempo queremos comparar los tres algoritmos A, B y C.

## 7.1. Supuestos

1. Los residuos son normalmente distribuidos, aunque se puede tolerar una desviación moderada de la normalidad
2. Se requiere que los grupos tengan homocedasticidad, la misma varianza. El valor de una observación no se ve afectado por alguna otra observación.
3. Las observaciones entre grupos son independientes.

## 7.2. Ejemplo R Anova

Se deben de instalar las siguientes librerías en el R-base

```
1 if(!require(psych)){install.packages("psych", dependencies = TRUE)}
2 if(!require(FSA)){install.packages("FSA")}
3 if(!require(Rmisc)){install.packages("Rmisc")}
4 if(!require(ggplot)){install.packages("ggplot")}
5 if(!require(car)){install.packages("car", dependencies = TRUE)}
6 if(!require(multcompView)){install.packages("multcompView", dependencies = TRUE)}
7 if(!require(multcompView)){install.packages("multcomp", dependencies = TRUE)}
8 if(!require(ismmeans)){install.packages("ismmeans", dependencies = TRUE)}
9 if(!require(rcompanion)){install.packages("rcompanion", dependencies = TRUE)}
```

Se carga la Data en formato texto, muy similar al ejemplo anterior. Se hace uso de la función *factor*, para modificar la columna Algoritmo como los factores a utilizar

```
1 Datos = ("
2 Algoritmo      Ejecucion  Tiempo
3 'Algoritmo A'   '1'      12060
4 'Algoritmo A'   '2'      14089
5 'Algoritmo A'   '3'      13502
6 'Algoritmo A'   '4'       9574
7 'Algoritmo A'   '5'     14056
8 'Algoritmo A'   '6'     11569
9 'Algoritmo A'   '7'     13047
10 'Algoritmo A'   '8'     13275
11 'Algoritmo A'   '9'     14257
12 'Algoritmo A'  '10'     15075
13 'Algoritmo A'  '11'     12506
14 'Algoritmo A'  '12'     11557
15 'Algoritmo A'  '13'       9548
16 'Algoritmo A'  '14'     11514
17 'Algoritmo A'  '15'     16015
18 'Algoritmo A'  '16'     13004
19 'Algoritmo A'  '17'     10510
20 'Algoritmo A'  '18'     13040
21 'Algoritmo A'  '19'     17098
22 'Algoritmo A'  '20'     13080
23 'Algoritmo B'   '1'     11080
24 'Algoritmo B'   '2'     12089
25 'Algoritmo B'   '3'     12538
26 'Algoritmo B'   '4'     10571
27 'Algoritmo B'   '5'     12010
28 'Algoritmo B'   '6'     12598
29 'Algoritmo B'   '7'     13543
30 'Algoritmo B'   '8'     13547
31 'Algoritmo B'   '9'     13217
32 'Algoritmo B'  '10'     15297
33 'Algoritmo B'  '11'     12210
34 'Algoritmo B'  '12'     11299
35 'Algoritmo B'  '13'     10067
36 'Algoritmo B'  '14'     11279
37 'Algoritmo B'  '15'     14006
38 'Algoritmo B'  '16'     12099
39 'Algoritmo B'  '17'     11581
40 'Algoritmo B'  '18'     14012
41 'Algoritmo B'  '19'     15069
```

```

42 'Algoritmo B'      '20'  12000
43 'Algoritmo C'      '1'    9081
44 'Algoritmo C'      '2'   11012
45 'Algoritmo C'      '3'   11529
46 'Algoritmo C'      '4'   9569
47 'Algoritmo C'      '5'   11092
48 'Algoritmo C'      '6'   11524
49 'Algoritmo C'      '7'   12522
50 'Algoritmo C'      '8'   12588
51 'Algoritmo C'      '9'   12241
52 'Algoritmo C'     '10'  13257
53 'Algoritmo C'     '11'  11294
54 'Algoritmo C'     '12'  10226
55 'Algoritmo C'     '13'   9591
56 'Algoritmo C'     '14'   9224
57 'Algoritmo C'     '15'  12033
58 'Algoritmo C'     '16'  11063
59 'Algoritmo C'     '17'   9537
60 'Algoritmo C'     '18'  13014
61 'Algoritmo C'     '19'  14033
62 'Algoritmo C'     '20'  11093
63   ")
64
65 # Load Data and RM String text
66 Data = read.table(textConnection(Datos), header = T)
67
68 rm(Datos)
69
70
71 Data$Algoritmo = factor(Data$Algoritmo, levels = unique(Data$Algoritmo))

```

Se hace un resumen sobre los tipos y nombres de las columnas. Además de un resumen de las medidas de posición central por grupos.

```

1 library(psych)
2 headtail(Data)
3 str(Data)
4 summary(Data)

```

Es importante considerar hacer un resumen de las medidas de posición central para cada grupo o tipo de algoritmo

```

1 Summarize(Tiempo ~ Algoritmo, data = Data, digits = 4)

```

El código anterior tiene como output:

```

      Algoritmo n      mean      sd  min      Q1 median      Q3  max
1 Algoritmo A 20 12918.80 1941.191  9548 11566.00 13043.5 14064.25 17098
2 Algoritmo B 20 12505.60 1414.667 10067 11510.50 12154.5 13544.00 15297
3 Algoritmo C 20 11276.15 1424.242  9081 10067.25 11193.5 12311.25 14033

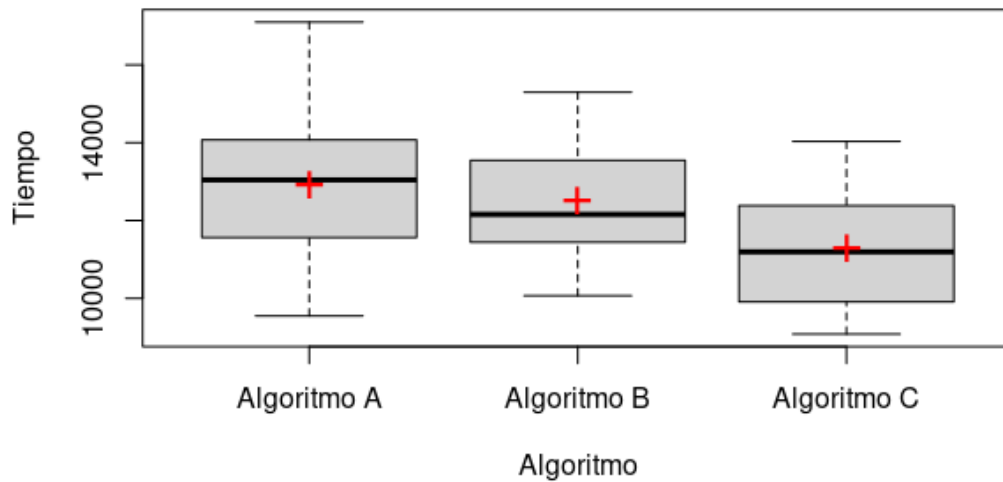
```

El siguiente código permite visualizar un box plot para los tres grupos A, B y C

```

1 #Box Plots
2
3 M = tapply(Data$Tiempo, Data$Algoritmo, mean)
4
5 boxplot(Tiempo ~ Algoritmo, data=Data)
6
7 points(M, col="red", pch="+", cex=2)

```



El el grafico ?? se puede ver que la media del Algoritmo A, osea casi el 50 % de los datos está por encima de C. Además de que el tercer cuartil, o sea el 75 % de los datos esta por debajo de el 50 % de A

### 7.3. Gráficos de Intervalos de Confianza


El el siguiente código se crea un intervalo de confianza al 95 %

```
1
2 library(rcompanion)
3
4 sum = groupwiseMean(
5   Tiempo ~ Algoritmo,
6   data=Data,
7   conf=0.95,
8   digit=3,
9   traditional = FALSE,
10  percentile = TRUE
11 )
```

	Algoritmo	n	Mean	Conf.level	Percentile.lower	Percentile.upper
1	Algoritmo A	20	12900	0.95	12100	13800
2	Algoritmo B	20	12500	0.95	11900	13100
3	Algoritmo C	20	11300	0.95	10700	11900

Graficando los intervalos de confianza se tiene lo siguiente:

```
1
2 library(ggplot2)
3
4 ggplot(sum, aes(x= Algoritmo, y=Mean))+
5   geom_errorbar(aes(ymin=Percentile.lower, ymax=Percentile.upper), width=0.05,size=0.5) +
6   geom_point(shape=15, size=4)+
7   theme_bw()+
8   theme(axis.title = element_text(face = "bold")) +
9   ylab("Tiempo promedio. s")
```



Como se puede ver en la imagen ??, el 95 % de los datos no se traslapan con A ni con B.

Cuando los gráficos no se traslapan podemos afirmar que no son estadísticamente diferentes. Sin embargo si se traslapan hay que ejecutar la prueba

Los intervalos de confianza presentan las siguientes características.

- Funcionan para indicar que tan precisa puee ser una estadística calcula
- Esta asociada al error de muestreo(diferencia entre el promedio de la población y la muestra).
- El intervalo nos dice que tan precisa puede ser nuestra inferencia
- El rango del intervalo de confianza expresa donde puede estar el promedio de la población.

#### Nivel de Confianza:

Si los intervalos de confianza de dos grupos no se traslapan pordemos asegurar que son estadísticamente diferentes. No hace falta realizar una prueba para demostrarlo.

#### Nivel de Confianza:

Es la probabilidad de que la estimación de la ubicación para un parámetro estadístico (por ejemplo un promedio) de una muestra sea igual al de la población.

## 7.4. Modelo Lineal

### Modelo Lineal

Una variable dependiente es predictiva por un conjunto de variables independientes a través de una regresión lineal.

Todos los modelos lineales tiene supuestos sobre los datos.

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i \quad (3)$$

### R-cuadrado

Es una medida que describe que tan bien el modelo explica los datos. Es una estadística de Goodness-fit

**Ejemplo:** un R-cuadrado de 0.6 indica que el 60 % de la variabilidad de la variable dependientes es explicada por el modelo.

P-value indica si hay una relación significativa descrita por el modelo. R-cuadrado mide el grado sobre el cual los datos son explicados por el modelo.

```
1 # Modelo
2 model = lm(Tiempo ~ Algoritmo, data = Data)
3 summary(model)
```

```
Call:
lm(formula = Tiempo ~ Algoritmo, data = Data)

Residuals:
    Min       1Q   Median       3Q      Max
-3370.8 -1211.6   25.1  1065.4  4179.2

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    12918.8     360.5  35.835 < 0.0000000000000002 ***
AlgoritmoAlgoritmo B    -413.2     509.8   -0.810    0.42105
AlgoritmoAlgoritmo C   -1642.7     509.8   -3.222    0.00211 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1612 on 57 degrees of freedom
Multiple R-squared:  0.1647,    Adjusted R-squared:  0.1353
F-statistic: 5.618 on 2 and 57 DF,  p-value: 0.005932
```

## 7.5. Ejecución del Anova

```
1 library(car)
2 Anova(model, type= "II" ) #Suma de cuadrados
```



### Anova Table (Type II tests)

Response: Tiempo

	Sum Sq	Df	F value	Pr(>F)
Algoritmo	29203870	2	5.6176	0.005932 **
Residuals	148161499	57		

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Es posible graficar los histogramas de los residuos.

```
1 X = residuals(model)
2 library(rcompanion)
3 plotNormalHistogram(X)
4 plot(fitted(model),residuals(model))
5 plot(model)
```

